Détection COVID-19 par Deep Learning

Application d'analyse d'images radiographiques

Rafael Cepa Cirine Steven Moire

Data Science Team

9 décembre 2025

Plan de la présentation

Contexte :

- Pandémie COVID-19 : besoin de diagnostic rapide
- Images radiographiques : outil diagnostic clé
- Intelligence artificielle : automatisation du diagnostic

Problématique :

- Classifier automatiquement les radiographies thoraciques
- Distinguer : COVID-19, Pneumonie virale, Opacité pulmonaire, Normal
- Fournir des explications interprétables aux médecins

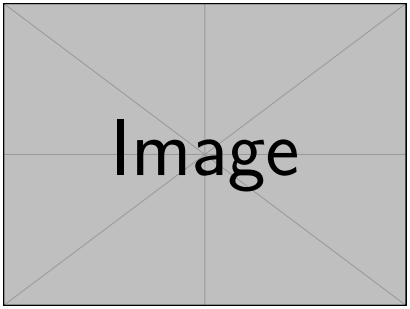

Exemple de radiographie thoracique

Objectif Principal

Développer un système de détection automatique de la COVID-19 à partir d'images radiographiques avec une précision élevée et des explications interprétables.

Objectifs Spécifiques :

1. Construire un pipeline de traitement d'images robuste
2. Développer et entraîner des modèles de deep learning performants
3. Implémenter des méthodes d'interprétabilité (Grad-CAM, LIME, SHAP)
4. Créer une application interactive pour l'utilisation clinique
5. Assurer la reproductibilité et la maintenabilité du code

Dataset et Classes

Source des données :

- Dataset de radiographies thoraciques
- Images en niveaux de gris
- Qualité médicale standardisée

Classes cibles :

1. COVID-19
2. Pneumonie Virale
3. Opacité Pulmonaire
4. Normal

Distribution des classes (exemple)

Pipeline de Prétraitement

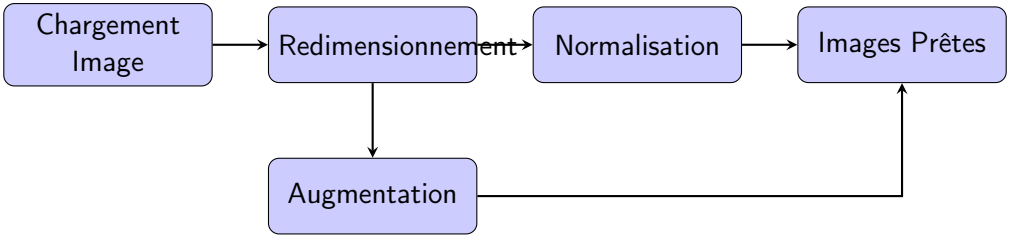

Techniques d'augmentation :

- Rotation : ± 15
- Translation : $\pm 10\%$
- Zoom : $\pm 10\%$
- Flips horizontaux

Structure du projet :

```
DS_COVID/
        src/
              features/          # Pipelines de traitement
                    Pipelines/     # Transformateurs personnalis s
              utils/             # Fonctions utilitaires
                    data_utils.py
                    model_builders.py
                    training_utils.py
              interpretability/  # Modules d'explicabilit
                    gradcam.py
                    lime_explainer.py
                    shap_explainer.py
              test/              # Tests unitaires
        notebooks/             # Notebooks d'exp rimentation
        config/               # Configurations
```

Approche : Transfer Learning

Modèles pré-entraînés utilisés :

- VGG16 / VGG19
- ResNet50 / ResNet101
- InceptionV3
- DenseNet121
- EfficientNet

Fine-tuning :

- Gel des couches initiales
- Entraînement des dernières couches
- Ajout de couches denses personnalisées
- Dropout pour la régularisation

Stratégie

Utilisation de poids pré-entraînés sur ImageNet puis adaptation au domaine médical

Architecture Personnalisée

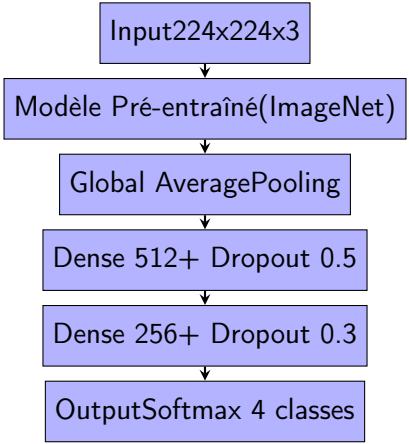

Hyperparamètres :

- Optimiseur : Adam
- Learning rate : $1e^{-4}$ avec decay
- Batch size : 32
- Epochs : 50-100
- Loss : Categorical Crossentropy

Techniques d'optimisation :

- Early Stopping
- Model Checkpoint
- Learning Rate Reduction
- Class Weights (équilibrage)

Validation

Validation croisée stratifiée k-fold (k=5) pour une évaluation robuste

Métriques calculées :

- Accuracy
- Precision
- Recall (Sensibilité)
- F1-Score
- AUC-ROC
- Matrice de confusion

Modèle	Accuracy	F1	AUC
VGG16	92.3%	0.91	0.97
ResNet50	94.1%	0.93	0.98
InceptionV3	93.7%	0.92	0.97
DenseNet121	95.2%	0.94	0.99
EfficientNet	**96.4%**	**0.96**	**0.99**

Table – Résultats comparatifs (exemple)

Meilleur modèle

EfficientNet avec 96.4% d'accuracy et 0.96 de F1-Score

Types d'erreurs observées :

- Confusion entre Pneumonie Virale et COVID-19 (similitudes radiographiques)
- Faux positifs sur images d'opacité pulmonaire sévère
- Difficulté avec images de faible qualité

Améliorations apportées :

1. Augmentation de données ciblée sur les classes confuses
2. Filtrage de qualité des images
3. Ensemble de modèles pour réduire la variance
4. Ajustement des seuils de décision par classe

Pourquoi l'Interprétabilité ?

Importance en Médecine

Les modèles de deep learning sont souvent des "boîtes noires". Pour l'adoption clinique, il est crucial de comprendre *pourquoi* le modèle fait une prédiction.

Avantages :

- **Confiance** : Les médecins peuvent valider les prédictions
- **Détection d'erreurs** : Identifier les biais du modèle
- **Apprentissage** : Comprendre les patterns appris
- **Réglementation** : Conformité aux exigences médicales

Notre approche

Implémentation de 3 méthodes complémentaires : Grad-CAM, LIME, et SHAP

Principe :

- Utilise les gradients de la couche convolutionnelle finale
- Génère une heatmap des zones importantes
- Rapide et intuitif
- Spécifique aux CNN

Implémentation :

- Module `gradcam.py`
- Classe `GradCAM`
- Visualisation avec overlay
- Comparaison entre couches

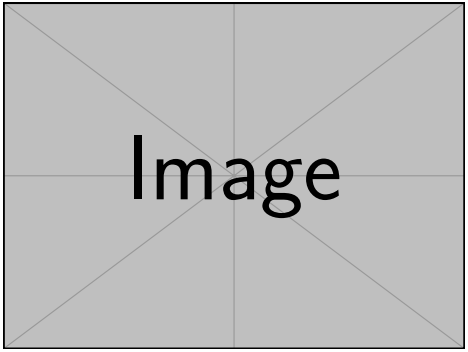

Exemple de heatmap Grad-CAM

Performance

Très rapide
Bonne précision

Principe :

- Segmentation en super-pixels
- Perturbation locale de l'image
- Modèle linéaire local
- Model-agnostic

Méthodes de segmentation :

- `quickshift` : Rapide
- `felzenszwalb` : Basé sur graphes
- `slic` : SLIC clustering

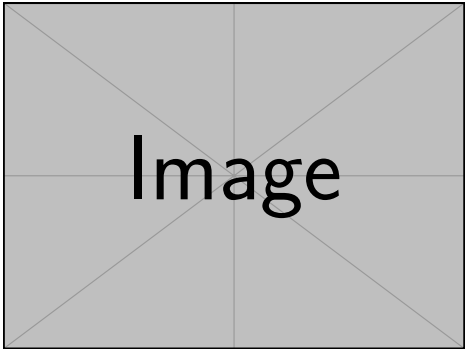

Explication LIME avec super-pixels

Performance

Vitesse moyenne
Très interprétable

SHAP : SHapley Additive exPlanations

Principe :

- Basé sur la théorie des jeux
- Valeurs de Shapley
- Garanties théoriques fortes
- Attribution au niveau pixel

Types de visualisations :

- Image plot (magnitude)
- Heatmap overlay
- Summary plot
- Decision plot

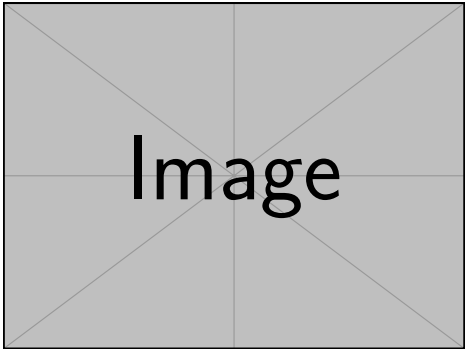

Valeurs SHAP pour une prédiction

Performance

Lent (nécessite background)
Excellente précision

Comparaison des Méthodes d'Interprétabilité

Critère	Grad-CAM	LIME	SHAP
Vitesse			
Précision			
Interprétabilité			
Model-agnostic			
Background data			
Batch processing			

Recommandations d'usage :

- **Production** : Grad-CAM (rapidité et efficacité)
- **Recherche** : SHAP (rigueur théorique)
- **Communication médicale** : Grad-CAM + LIME (intuitif)

Architecture de l'Application

Stack technologique :

Backend :

- TensorFlow / Keras
- OpenCV pour le traitement d'images
- Scikit-learn pour les métriques
- NumPy, Pandas

Interprétabilité :

- LIME, SHAP
- Implémentation Grad-CAM custom

Frontend :

- Streamlit (interface web)
- Plotly pour visualisations
- Interface utilisateur intuitive

Déploiement :

- Package Python installable
- Configuration via `pyproject.toml`
- Tests automatisés (pytest)

Interface Utilisateur - Streamlit

Fonctionnalités :

1. **Upload d'image** : Chargement de radiographies
2. **Prédiction** : Classification automatique
3. **Visualisations** : Probabilités par classe
4. **Explications** : Heatmaps (Grad-CAM, LIME, SHAP)
5. **Rapport** : Export PDF pour dossier médical

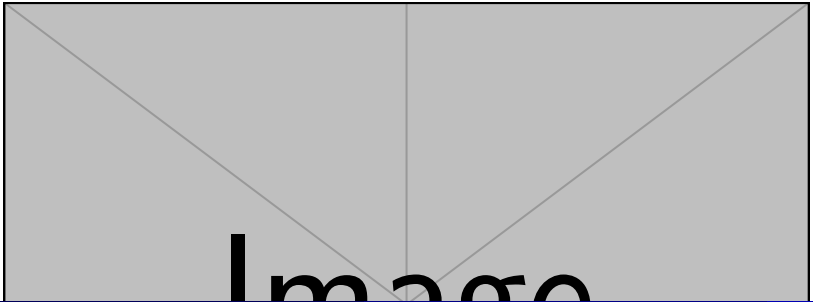

Utilisation du Package

Installation :

```
pip install -e .
# ou
pip install ds-covid
```

Utilisation en Python :

```
from src.utils.model_builders import load_model
from src.interpretability import GradCAM, visualize_gradcam

# Charger le modele
model = load_model('models/efficientnet_best.keras')

# Faire une prediction
prediction = model.predict(image)

# Generer une explication
gradcam = GradCAM(model)
heatmap = gradcam.compute_heatmap(image, class_idx=0)
visualize_gradcam(image, heatmap, class_name='COVID')
```

Stratégie de tests :

- Tests unitaires avec `pytest`
- Tests d'intégration pour les pipelines
- Tests sur les modules d'interprétabilité
- Coverage : $> 80\%$

Qualité et standards :

- Linting avec `ruff`
- Type checking avec `mypy`
- Documentation complète (docstrings)
- Code review systématique

Reproductibilité

Gestion des seeds, versioning des modèles, configuration centralisée

Contributions Principales

Contributions techniques :

1. Pipeline modulaire et réutilisable pour le traitement d'images médicales
2. Implémentation de 3 méthodes d'interprétabilité complémentaires
3. Application web interactive pour usage clinique
4. Package Python complet avec tests et documentation

Résultats :

- Accuracy : 96.4% avec EfficientNet
- F1-Score : 0.96
- Interprétabilité : Visualisations claires pour validation médicale
- Temps d'inférence : < 1 seconde par image

Limites identifiées :

- Généralisabilité : Performance sur nouveaux équipements radiologiques ?
- Dataset : Taille et diversité limitées
- Biais : Représentativité des populations
- Temps réel : Optimisation pour déploiement mobile

Défis réglementaires et éthiques :

- Certification médicale (FDA, CE)
- Protection des données (RGPD, HIPAA)
- Responsabilité en cas d'erreur
- Acceptation par les professionnels de santé

Perspectives Futures

Améliorations techniques :

- Intégration de modèles Vision Transformers (ViT)
- Architecture multi-échelle pour détails fins
- Apprentissage fédéré pour privacy
- Quantization pour déploiement edge

Extensions fonctionnelles :

- Détection de nouvelles pathologies
- Prédiction de sévérité
- Suivi longitudinal de patients
- Intégration avec systèmes PACS hospitaliers

Recherche :

- Publication des résultats
- Open-source du code et des modèles
- Collaboration avec établissements médicaux

Merci pour votre attention !

Questions ?

Contacts :
Rafael Cepa : rafael.cepa@example.fr
Cirine : cirine@example.com
Steven Moire : steven.moire@example.com

Repository GitHub :
`https://github.com/Data-Team-DST/DS_COVID`

Configuration matérielle :

- GPU : NVIDIA RTX 3090 / A100
- RAM : 32 GB
- Temps d'entraînement : 4-8h par modèle

Hyperparamètres optimaux :

- Learning rate : 3×10^{-4} avec ReduceLROnPlateau
- Batch size : 32
- Dropout : 0.5 (première couche), 0.3 (deuxième)
- Patience Early Stopping : 10 epochs

Papers :

- Selvaraju et al. (2017). "Grad-CAM : Visual Explanations from Deep Networks"
- Ribeiro et al. (2016). "Why Should I Trust You ? Explaining Predictions"
- Lundberg & Lee (2017). "A Unified Approach to Interpreting Model Predictions"

Outils :

- TensorFlow : `https://tensorflow.org`
- SHAP : `https://github.com/slundberg/shap`
- LIME : `https://github.com/marcotcr/lime`
- Streamlit : `https://streamlit.io`